

Reporte Actividad 3.1

Preprocesamiento de Datos

Variables Seleccionadas:

- host_response_rate
- host_acceptance_rate
- host_total_listings_count
- accommodates
- reviews_per_month
- price

Tratamiento de Nulos: Se identificaron valores nulos en las variables de tipo numérico y de porcentaje. Se imputaron utilizando la mediana, dado que es resistente a valores extremos (outliers).

Conversión de Datos:

- Se eliminaron símbolos como % y \$, y se convirtieron las columnas host_response_rate, host_acceptance_rate y price a tipo float.
- Esto permitió realizar análisis cuantitativos sin errores de tipo de dato.

Eliminación de Outliers: Se aplicó el método del Rango Intercuartílico (IQR) para eliminar valores atípicos en todas las columnas. Esto permitió reducir la distorsión en los análisis posteriores.

Análisis de Correlación No Lineal

Se calcularon dos tipos de correlación no lineal para cada par de variables:

- Spearman: evalúa si existe una relación monótona (no necesariamente lineal) entre dos variables.
- Kendall: mide la consistencia en el ordenamiento de los datos entre dos variables.

Algunas correlaciones no pudieron calcularse (NaN), debido a que ciertos valores eran constantes después de eliminar outliers (host_response_rate).

```
# 6 Análisis de correlación no lineal (Spearman y Kendall)
correlaciones = []
for x in variables:
    for y in variables:
        if x != y:
            try:
                spearman_corr, _ = spearmanr(df_sin_outliers[x], df_sin_outliers[y])
                kendall_corr, _ = kendalltau(df_sin_outliers[x], df_sin_outliers[y])
                correlaciones.append({
                    'Variable X': x,
                    'Variable Y': y,
                    'Spearman': round(spearman_corr, 4),
                    'Kendall': round(kendall_corr, 4)
                })
            except:
                correlaciones.append({
                    'Variable X': x,
                    'Variable Y': y,
                    'Spearman': np.nan,
                    'Kendall': np.nan
                })

df_correlaciones = pd.DataFrame(correlaciones)
```

Regresión No Lineal (Polinomial de Grado 2)

- Se aplicó un modelo de regresión polinomial entre cada par de variables seleccionadas.
- Se calculó el coeficiente de determinación que indica qué tan bien se ajusta el modelo a los datos.

```
# 7 Regresión no lineal (polinomial grado 2)
regresion_resultados = []
for x_var in variables:
    for y_var in variables:
        if x_var != y_var:
            X = df_sin_outliers[[x_var]].values
            y = df_sin_outliers[y_var].values

            poly = PolynomialFeatures(degree=2)
            X_poly = poly.fit_transform(X)

            model = LinearRegression().fit(X_poly, y)
            y_pred = model.predict(X_poly)

            r2 = r2_score(y, y_pred)

            try:
                spearman_corr, _ = spearmanr(df_sin_outliers[x_var], df_sin_outliers[y_var])
                kendall_corr, _ = kendalltau(df_sin_outliers[x_var], df_sin_outliers[y_var])
            except:
                spearman_corr, kendall_corr = np.nan, np.nan

            regresion_resultados.append({
                'Variable X': x_var,
                'Variable Y': y_var,
                'Modelo': 'Polinomial grado 2',
                'R^2': round(r2, 4),
                'Spearman': round(spearman_corr, 4),
                'Kendall': round(kendall_corr, 4)
            })
```

Comparación de resultados

Aspecto Analizado	Correlacion Spearman/Kendall	Regresion Polinomial
Relacion entre pares	Si	Si
Deteccion de tendencia	Monotona	Curva cuadratica
Sensibilidad a outliers	Baja	Alta
Coeficiente comparativo	Spearman/Kendall $([-1, 1])$	

Conclusión

El análisis permitió detectar que algunas variables, como `host_acceptance_rate` y `price`, tienen correlaciones moderadas o bajas entre sí. La regresión polinomial mostró que pocas relaciones tienen un R^2 alto, lo que indica que no hay fuertes relaciones predictivas cuadráticas entre las variables seleccionadas. El preprocesamiento fue esencial para limpiar el dataset y obtener resultados confiables.